程钟泉

男 | 2003年出生（22岁） | 户籍：上海
chengzhongquan0630@gmail.com | z.cheng@wustl.edu | 315-317-5618
现居：美国 · 密苏里州 · 圣路易斯



教育背景

圣路易斯华盛顿大学（Washington University in St. Louis） 2025.08 – 2026.06（预计）
计算机科学 硕士 | GPA: 3.7/4.0 | 核心课程：高级算法、分布式系统、机器学习应用、计算机视觉

雪城大学（Syracuse University） 2021.09 – 2025.05
计算机科学 学士 | 扎实的算法、数据结构与软件工程基础

工作经历

Undergraduation.com — 后端与AI工程实习生 2025.09 – 至今
- 设计基于 SSE 的分布式请求管线，结合 Vercel Serverless 异步调度，支撑 50+ 并发用户零阻塞
- 构建 Agentic Chatbot 系统，集成 LLM Tool Calling 实现动态多步任务编排，自动完成数据查询、表单填充与第三方 API 调用等复杂工作流
- 构建容错型 LLM 网关，实现延迟感知的 A/B Provider 自动故障转移，保障系统高可用并优化 Token 成本
- 设计 PostgreSQL 复合键缓存策略消除 40% 冗余查询；实施 RLS + API 中间件纵深防御，确保多租户零数据泄漏

`Node.js` `Supabase` `PostgreSQL` `Vercel` `Pinecone` `Redis` `LLM Tool Calling` `LangChain`

金光集团 APP（Asia Pulp & Paper）— 数据科学实习生 2023.05 – 2023.06 | 上海
- 基于 XGBoost 构建时序销售预测引擎，工程化滞后特征捕捉季节性波动，预测准确率达 92%，支撑库存优化决策
- 设计自动化 ETL 管线，通过 CTE 与索引优化 SQL 查询，数据抽取延迟降低 40%
- 利用 Pandas 向量化替代循环处理高维交易数据，识别关键销售趋势为上海区域生产策略提供数据支撑

`Python` `SQL` `XGBoost` `Scikit-learn` `Pandas` `ETL` `数据仓库`

科研经历

AI for Health Institute, WashU — 计算机视觉研究员 2025.01 – 至今
- 构建视频隐私管线，集成 Meta Sapiens 与 OpenCV 实现 16 类人体部位语义分割（10,000+ 帧）；设计动态曝光调节与时序质量分析，低光照检测率提升 80%
- 基于 LangGraph 构建多智能体序列错误检测系统（感知、校验、状态追踪、监督 4 Agent），实现快回路（vLLM 4B）+ 慢回路（vLLM 8B）双环实时操作合规监测
- 部署 vLLM 推理服务器运行 Qwen3-VL 双模型级联架构，结合 FP8 量化、PagedAttention 与前缀缓存，16 线程并行管线将单片段延迟从 200ms 降至 120ms
- 设计 Video-STaR 启发的分阶段训练管线（SFT → 难负例挖掘 → 时序扩展 → 工具增强），基于 Qwen 27B + LoRA 在 79,600 平衡样本上从 ~75% 逐阶段提升至 85.47%
- 提出 DeAR（Decomposing Attention Head Roles），对 ViT 注意力头按熵值分类并注入可学习属性 Token 与角色注意力掩码，针对性强化弱类识别
- 引入 YOLO ROI 裁剪预处理，消除 ~70% 无关背景噪声，在 VLM 推理前提升有效分辨率与手-物交互识别精度
- 开发 FastAPI 实时仪表盘，支持 SSE 推流、HITL 人工审核队列与 ThreadPoolExecutor 并发管线，可处理 12,000+ 帧长视频

`Python` `vLLM` `Qwen3-VL (4B/8B/27B)` `LangGraph` `FastAPI` `PyTorch` `LoRA` `YOLO` `OpenCV` `Docker` `Meta Sapiens`

雪城大学 — 研究助理（导师：Prof. Asif Salekin） 2024.02 – 至今
- 基于工厂设计模式构建可扩展 Android 数据采集框架，解耦传感器实现层支持多模态 IMU 数据流灵活扩展
- 使用 Docker Compose 容器化 ML 管线；设计 CNN-LSTM 混合网络，抑郁症生物标志物检测准确率达 87%

`Android/Kotlin` `Docker Compose` `CNN-LSTM` `IMU 传感器融合`

项目经历

VR 图书馆导航游戏 — 团队负责人（3人） 2022.09 – 2025.05
- 带领团队基于 Unity + C# 开发 VR 沉浸式教育游戏，独立实现图形特效渲染、手势识别交互与动态场景加载，完成原型并投入校内用户测试

`Unity` `C#` `VR 开发` `手势识别`

LLM 微调与优化 — F-lab 研究项目 2023.04 – 2023.05
- 基于 Python 对大语言模型进行领域微调（大学图书馆语料），应用 PEFT/LoRA 降低训练成本，在有限 GPU 算力下实现高效迭代

`Python` `LLM 微调` `PEFT` `LoRA`

专业技能

编程语言： Python、JavaScript/TypeScript、Kotlin、SQL、Java、C/C++、C#、R、Haskell
框架与工具： PyTorch、vLLM、LangGraph、LangChain、FastAPI、Node.js、React、Docker、OpenCV、FFmpeg、Git
数据与AI： Qwen3-VL、LoRA/PEFT、LLM Tool Calling、DPO/SFT 训练管线、YOLO、XGBoost、Scikit-learn、Pandas、Meta Sapiens
平台与数据库： PostgreSQL、Supabase、Redis、Pinecone、Linux、Vercel Serverless

学生活动

CuseHacks 年度黑客松 — 高级工作坊负责人 2023 – 2025
组织并主持雪城大学年度黑客松，制定竞赛规则推动包容性参与，为参赛者提供技术指导

中国学生联合会 — 摄影部成员 2021 – 2025
策划社团活动与视觉内容输出，促进校园多元文化交流与社区建设